

DALAS Project 2024-2025

Master Informatique – Semestre 2

Sorbonne Université

Comment gagner des élections ?

Auteurs :

Mathurin DE CRECY

Philipp HANUSSEK

1 Introduction

À l'ère numérique, l'information circule en continu et façonne les perceptions collectives. Jamais l'espace public n'a été aussi saturé de discours : médias d'information, réseaux sociaux, tribunes politiques et commentaires en boucle composent un environnement dense, parfois contradictoire, dans lequel l'électeur doit se repérer. Dans ce contexte, on est en droit de se demander : qu'est-ce qui influence réellement le choix des électeurs ? Est-ce la répétition de certains thèmes propres à certains partis dans les médias ? La rhétorique de ces mêmes partis politiques ? La situation économique ressentie par les électeurs ? Ou encore, plus simplement, la capacité d'un parti à financer efficacement sa campagne ? Chaque vote est motivé par de nombreux facteurs que nous ne percevons pas toujours mais qui sont autant de leviers dans le résultat final d'une élection. Ce travail de data science se propose donc de cartographier ces dynamiques à priori invisibles qui sous-tendent le vote, en mobilisant un ensemble hétérogène mais complémentaire de données. Nous allons donc explorer les liens entre sondages d'opinion publique, agenda médiatique, corpus de discours parlementaires, archives de presse et financement des partis dans le but de mieux cerner les dynamiques qui façonnent les scrutins. L'objectif n'est pas uniquement de prédire une intention de vote, mais de comprendre, par la donnée, comment l'espace discursif et les ressources matérielles interagissent avec l'opinion publique et les comportements électoraux. Pour ce faire, nous exploitons des jeux de données variés : résultats de sondages d'opinion (Politbarometer), archives de presse françaises et allemandes, corpus de discours issus de l'Assemblée nationale, ainsi que les comptes des partis politiques.

Ce rapport s'organise en cinq grandes parties, chacune répondant à un aspect clé de cette problématique :

1. L'opinion publique face à l'agenda médiatique : Nous confrontons les thématiques dominantes dans les sondages à celles reflétées par les journaux, afin de mesurer le degré d'alignement ou de décalage entre les médias et l'opinion publique. Des analyses de corrélation sont utilisées pour quantifier cette relation, en particulier dans les périodes de crise.
2. Langage politique vs langage médiatique : Grâce à des analyses en composantes principales et des mesures de similarité cosinus, nous explorons comment les mots-clés se structurent dans les discours politiques par rapport aux journaux. Quels partis "parlent le même langage" que les médias ? Lesquels sont en rupture ?
3. Modéliser le vote par apprentissage automatique : À partir des réponses à un sondage d'opinion, nous entraînons des modèles de classification (Random Forest et Gradient Boosting) pour prédire l'orientation politique des répondants. Cette section évalue la pertinence des variables et discute les performances des algorithmes.
4. Poids des mots et poids de l'argent : Nous analysons les flux financiers des partis politiques depuis 2008 et leur corrélation avec la représentation parlementaire. Une PCA permet d'isoler les variables budgétaires les plus discriminantes. Cette partie interroge la structure du financement politique dans un système de plus en plus fragmenté.
5. Synthèse et perspectives : Nous proposons une mise en perspective des résultats obtenus, en insistant sur les limites de notre approche (qualité des données, représentativité, biais structurels), et en ouvrant sur des pistes futures : élargissement des corpus, suivi longitudinal, analyse du rôle des réseaux sociaux, etc.

Ce rapport n'a pas la prétention d'épuiser la complexité du comportement électoral, mais il montre qu'en mobilisant intelligemment les données disponibles, il est possible de dessiner les contours d'un champ politique où l'information, les discours et l'argent forment un triangle d'influence majeur. Comprendre ce triangle, c'est aussi mieux comprendre les démocraties contemporaines.

2 Analyse exploratoire des données

2.1 Sondage *Politbarometer*

⇒ voir `JupyterNotebooks/cleaning_data/EDA_Politbarometer_Journaux.ipynb`

Le sondage *Politbarometer* [2] est organisé par l'institut scientifique *Forschungsgruppe Wahlen* pour la chaîne de télévision publique *ZDF*. Depuis 1977, chaque semaine, environ 1500 personnes sont interrogées dans le cadre du sondage en Allemagne. La sélection des participants est représentative de la population allemande. Le questionnaire contient environ 80 questions, dont certaines concernant l'intention de vote et l'ambiance politique générale, et des questions qui peuvent varier en fonction des sujets pertinents (par exemple, la pandémie de COVID).

Structure du fichier Les colonnes du jeu de données représentent les questions. Chaque ligne correspond aux réponses d'une personne interrogée. Les réponses aux questions sont enregistrées sous forme d'un chiffre (par exemple, pour la question concernant la partie politique préférée, chaque chiffre correspond à une partie). La signification de chaque code peut être repérée dans le manuel du sondage.

Valeurs manquants Comme les questions et réponses possible changent avec les évolutions politiques, on se concentre sur les sondages effectués depuis l'année 2000. Une analyse des valeurs manquants montre qu'il y a 30 colonnes (de 84 colonnes en total) où plus que 80% des données sont manquantes. Parfois, par exemple, le questionnaire change ou une question est posée juste dans certaines régions. Nous excluons ces 30 colonnes de l'analyse.

On supprime également toutes les réponses des personnes qui ont refusé de répondre à 10 questions ou plus ($\approx 20\%$ des réponses).

Cela nous permet de réduire la taille du jeu de données de presque 50%.

Réduction de dimension Comme il s'agit de données catégoriques, nous effectuons une analyse à correspondance multiple (ACM) qui effectue d'abord un codage one-hot et après une analyse de correspondance. Malheureusement, la variance cumulée est trop faible pour réduire les dimensions.

2.2 Scrapping des Journaux

⇒ voir `JupyterNotebooks/scrapping`

Nous avons sélectionné les journaux suivants, qui représentent une diversité d'opinion en France et en Allemagne :

- Le Figaro (centre-droit)
- Libération (centre-gauche)
- Le Monde (centre)
- Frankfurter Allgemeine Zeitung *FAZ* (centre-droit)
- die Tageszeitung *taz* (centre-gauche)

Méthodologie L'analyse des archives des journaux est effectué de la manière suivant : D'abord, nous avons identifié des mots clés de la politique. Puis, nous utilisons le moteur de recherche des archives concernés et nous comptons de manière automatique le nombre d'articles qui contiennent ce mot clé. Cette approche présente des inconvénients, en particulier :

- Un mot clé peut apparaître dans un autre contexte (par exemple, le mot «sécurité» peut être utilisé dans le contexte de la sécurité nationale, ou de la sécurité sociale)
- A travers des journaux, des articles peuvent être comptés plusieurs fois si ils sont fournis par une agence nationale, par exemple l'AFP

Cependant, cette méthode nous permet de récupérer une grande quantité des données facilement.

Structure du fichier Les colonnes représentent les mots clés et les lignes les années.

Valeurs manquants Il n'y a pas de valeurs manquants.

Visualisation de données Pour mieux comprendre les données récupérées, voir [figure 1](#) et [figure 2](#).




FIGURE 1 – Fraction des articles publiés dans les journaux *FAZ* et *TAZ* pour chaque mot clé entre les années 2000 et 2025.




FIGURE 2 – Proportion relative des articles parus entre 2000 et 2025 dans le journal allemand *FAZ* pour les sept mots-clés les plus fréquemment mentionnés. Le mot-clé « covid » a été ajouté car il illustre l'impact qu'un événement exceptionnel peut avoir sur la couverture médiatique.

La matrice de corrélation (voir [figure 3](#)) montre la plus forte corrélation pour les mots clés « Covid » et « Système de Santé ». On peut aussi observer une corrélation entre les mots « crise financière » et « dette publique » ce qui relève du fait que la crise financière des années 2010 était surtout une crise de dettes publiques.




FIGURE 3 – Corrélation entre les mots clés des articles parus entre 2000 et 2025 dans le journal allemand *TAZ* pour les sept mots-clés les plus fréquemment mentionnés.

2.3 Discours

⇒ voir `JupyterNotebooks/scrapping/discours.ipynb`

L'étude des discours politiques constitue un levier essentiel pour comprendre les dynamiques idéologiques et sémantiques au sein du champ politique. Dans cette perspective, nous avons constitué un corpus de discours prononcés à l'Assemblée nationale française entre 2002 et 2025, en nous appuyant sur les archives disponibles sur le portail institutionnel *vie-publique.fr*. Ce corpus permet d'observer, dans la durée, les inflexions lexicales, les thématiques dominantes, et les styles rhétoriques propres à chaque groupe parlementaire.

Cependant, cette source présente des biais structurels qu'il convient de prendre en compte. Les discours enregistrés proviennent exclusivement des prises de parole officielles au sein de l'hémicycle. Ils excluent donc d'importants pans de la communication politique contemporaine, notamment les interventions médiatiques, les discours de campagne ou encore les publications sur les réseaux sociaux. De plus, en raison des contraintes de documentation et d'archivage, les données sont très inégalement réparties dans le temps. Les premières années sont sous-représentées, tandis que les périodes récentes, où l'archivage s'est automatisé, offrent une densité bien supérieure. Enfin, la logique même du fonctionnement parlementaire entraîne une surreprésentation mécanique des groupes majoritaires, qui disposent de plus de temps de parole. Les partis émergents ou minoritaires, en particulier ceux n'ayant obtenu

que quelques sièges, sont ainsi souvent absents ou très peu présents dans le corpus.

2.4 Finances

⇒ voir `JupyterNotebooks/scrapping/scrap_finances.ipynb`

Le quatrième grand axe d'exploration de notre étude concerne les données financières des partis politiques français, entre 2008 et 2022. Ce jeu de données provient également de la plateforme vie-publique.fr, qui centralise les déclarations annuelles de revenus et de dépenses émanant des principales formations politiques. Ces déclarations permettent de quantifier précisément les ressources mobilisées par chaque parti : subventions publiques, dons privés, cotisations des élus, emprunts bancaires, frais de communication, dépenses de personnel, achats de matériel, etc.

Afin de rendre le corpus exploitable sur un plan statistique, un important travail de nettoyage et de normalisation a été réalisé. Les colonnes redondantes ou spécifiques à certaines années ont été supprimées, et certaines catégories budgétaires ont été fusionnées pour assurer l'homogénéité entre les périodes. Le jeu de données final se compose ainsi de 171 observations, correspondant à des couples (parti, année), et de 56 variables financières standardisées, contre 5400 couples et 118 variable initialement. Ce format nous permet non seulement d'étudier les flux monétaires dans le temps, mais aussi d'envisager des analyses multivariées visant à déceler des profils financiers typiques selon le poids électoral des partis.




FIGURE 4 – Total des flux financiers des partis politiques français

Sur ce graphique on peut constater que les quantités d'argent utilisés par les partis politiques sont stables depuis 2008. On observe aussi des pics de dépenses lors des années électorales, en dehors de ces périodes les revenus ont tendances à être supérieurs aux dépenses. On remarquera également deux événements majeurs que sont la présidentielle de 2012, lors de laquelle l'ump a dépensé près de 100 millions d'euros à eux seuls, et la crise de covid-19 qui se traduit par une chute des dépenses et des revenus en 2020.

3 Analyse

3.1 Scrapping

⇒ voir `JupyterNotebooks/analyse/Analyse_Correlation_Sonage_Journaux.ipynb`

Pour répondre à la question si les sujets choisis par les journaux correspondent aux problèmes de la population, nous avons analysé le rapport entre le nombre d'articles publiés et le sondage *Politbarometer*. Comme le sondage est organisé en Allemagne, notre analyse ne contient pas de données pour la France. Lors du sondage, les personnes interrogées sont invitées à répondre à la question : «À votre avis, quel est le problème le plus pertinent actuellement en Allemagne?». La réponse peut être un des 137 problèmes définis à l'avance, par exemple «terrorisme» ou «infrastructure». D'abord, nous avons identifié les 20 classes de problèmes les plus évoquées depuis l'année 2000 et nous effectuons ensuite une analyse des archives avec la méthode décrit en sous-section 2.2.




FIGURE 5 – Corrélation entre les sujet évoqués dans des articles et les classes de réponse dans le sondage en Allemagne. Pour chaque année de 2000 à 2022 inclus et chaque classe de problème, nous calculons la corrélation entre la fréquence de réponse de cette classe, et le nombre des articles dans lesquelles ce problème est évoqué. Les journaux analysés sont la *FAZ* (centre-droit) et la *TAZ* (centre-gauche).

3.1.1 Conclusion

Les résultats sont éclairants. Dans l'ensemble, une corrélation forte est observée pour les grandes thématiques transversales comme le chômage, l'économie ou l'immigration. Ces enjeux, structurellement présents dans l'actualité comme dans les sondages, constituent des points de convergence évidents. De manière plus marquée, certains événements exceptionnels produisent des pics de corrélation : la crise financière de 2008 et la pandémie de COVID-19 en 2020 en sont les exemples les plus frappants. Dans ces moments de crise, l'opinion public semble se contracter autour de quelques sujets particulièrement préoccupants, reflétés aussi bien dans les discours médiatiques que dans les inquiétudes des citoyens.

Cependant, cette coordination n'est ni uniforme ni permanente. Plusieurs thématiques importantes dans les sondages, comme les retraites ou l'environnement, connaissent une couverture médiatique plus irrégulière, ou moins corrélée dans le temps. Inversement, certains thèmes font l'objet d'un traitement

médiatique intensif sans être fortement mentionnés par les sondés, par exemple les affaires politiques ou les débats institutionnels.

Un autre résultat notable réside dans l'absence de différences significatives entre les deux journaux analysés, malgré leurs positionnements politiques distincts. Que l'on se tourne vers la FAZ (centre-droit) ou vers la TAZ (centre-gauche), la structure des corrélations reste très proche. Cela suggère que, sur les grandes thématiques, les journaux dits d'opinion partagent finalement un cadre de traitement relativement homogène, peut-être dicté par l'agenda national ou par les attentes supposées de leurs lecteurs.

3.2 Préparation d'un modèle pour prédire les résultats du scrutin

Peut-on, à partir des données disponibles, prédire la direction que prendra le vote d'un citoyen ? C'est l'hypothèse que nous souhaitons tester à travers la modélisation des résultats d'un sondage politique. Loin de prétendre reproduire avec exactitude le comportement électoral individuel, notre objectif est plutôt de mesurer dans quelle mesure les réponses à certaines questions permettent d'anticiper une orientation politique globale au sein d'une population, et donc de déterminer l'issue d'une élection. A partir du sondage *Politbarometer* notre but est de préparer un modèle qui peut prédire les préférences politiques d'une personne interrogée à partir des réponses aux autres questions. Pour faciliter l'entraînement d'un modèle, nous transformons la question en problème de classification binaire. La question cible est : est-ce que la personne vote pour une partie de gauche ou de droite ? Nous visons la question 6 du sondage : « Lors des prochaines élections, vous allez voter pour quelle partie ? ». Les partis ont été répartis en deux catégories selon leur orientation idéologique générale et seuls les sept partis les plus mentionnés ont été conservés pour assurer un volume d'observations suffisant. Les réponses relatives à des partis marginaux ont été exclues. Nous assignons la valeur `vrai` si une personne est plutôt favorable aux parties de gauche et `faux` si une personne vote pour une partie conservatrice. Cette transformation donne lieu à un jeu de données prêt pour l'apprentissage supervisé, avec une variable cible (gauche/droite) et une série de variables explicatives correspondant aux réponses aux autres questions du sondage (économie, emploi, environnement, Europe, etc.).

3.2.1 Préparation du modèle

⇒ voir `JupyterNotebooks/analyse/Random_Forest_Model.ipynb`

Pour construire ce modèle prédictif, nous avons testé deux algorithmes couramment utilisés dans les sciences sociales computationnelles[1] : les forêts aléatoires (Random Forest, RF) et le gradient boosting (HistGradientBoosting, HGB). Ces deux méthodes reposent sur des arbres de décision, mais diffèrent dans leur manière d'agréger les prédictions : le premier utilise la moyenne d'un grand nombre d'arbres indépendants, le second les construit de manière séquentielle pour corriger les erreurs de l'ensemble précédent.

Optimisation des hyperparamètres Une première analyse des courbes de validation a révélé un comportement typique (voir [figure 6](#)) : le modèle Random Forest atteint très rapidement une précision proche de 100 % sur les données d'entraînement, mais chute fortement en validation croisée. Ce symptôme de surapprentissage (overfitting) est bien connu : le modèle "mémorise" trop bien les réponses et échoue à généraliser. En comparaison, le modèle HGB progresse plus lentement, mais montre une meilleure robustesse.

Nous avons donc affiné les modèles à l'aide d'une recherche aléatoire d'hyperparamètres (RandomizedSearchCV). Les métriques sont générées avec la technique de validation croisée (avec $k = 5$ dans notre cas), afin de garantir une évaluation plus rigoureuse et éviter les effets de sur-ajustement. Par souci de coût de calcul, ce réglage a été effectué uniquement sur les données des années 2000 à 2020.

Entraînement du modèle Les modèles sont entraînés sur les données de l'année 2000 à 2020 incluses.

Test du modèle Pour les tests du modèle, nous utilisons les entrées de l'année 2021, pour éviter les risques de surapprentissage.




FIGURE 6 – Courbe de validation pour les forêts d’arbres aléatoires (RF) et gradient boost (HGB) avant réglage des paramètres. Modèles entraînés sur le jeu de données *Politbarometer* des années 2000 à 2020


Code	Caractéristique	Importance
v36	Qui améliore l’économie ?	40,8%
v35	Qui assure les emplois ?	23,5%
v34	Quel est le plus grand problème de Allemagne actuellement ?	4,5%

TABLE 1 – Aperçu des caractéristiques principales du modèle RF entraîné sur les données des années 2000 à 2020. La colonne « code » représente le codage de la question dans le sondage *Politbarometer*.

Observation Sur les données de test, les deux modèles affichent des résultats comparables : une précision d’environ 73 %, accompagnés d’un AUC (area under the curve) proche de 0.81. Ces performances, sans être exceptionnelles, montrent que des signaux prédictifs existent dans les réponses au sondage, même après simplification binaire.

3.2.2 Analyse des caractéristiques

Au-delà du score, l’un des avantages de la forêt aléatoire est de fournir une mesure de l’importance des variables (voir [tableau 1](#)). Dans notre cas, les trois questions les plus prédictives sont celles portant sur l’économie et l’emploi : "Quel parti améliore l’économie?", "Qui assure les emplois?", et, assez logiquement, la question centrale sur l’intention de vote elle-même. Cela confirme une intuition classique en science politique : l’économie est au cœur des clivages électoraux, mais aussi que certaines questions sont redondantes ou structurellement corrélées à la variable cible. Typiquement, les formulations des deux question *v36* et *v35* sont très similaires. Il est donc logique que les réponses données pour les questions sont similaires, ainsi si l’une des question est déterminante pour la prédiction du vote, l’autre le sera aussi.



(a) Courbe de ROC pour le jeu de test de l'année 2021

(b) Matrices de confusion des deux modèles.

FIGURE 7 – Évaluation des forêts d'arbres aléatoires (RF) et gradient boost (HGB) sur le jeu de données test après réglage de paramètres. Modèles entraînés sur le jeu de données *Politbarometer* pour les années 2000 à 2020.


Si ces résultats sont prometteurs, plusieurs limites doivent être soulignées. Le découpage gauche/droite, s'il a l'avantage de la clarté, masque la complexité des repositionnements idéologiques récents, notamment avec l'émergence de partis transversaux comme Renaissance. De plus, les modèles actuels ne prennent en compte que des réponses isolées, sans contextualisation temporelle, sociale ou géographique. Malgré ces limites, cette expérience montre qu'il est possible, avec des outils simples et des données bien préparées, d'anticiper une orientation politique à partir de déclarations non-explicites.

3.3 Analyse du langage

⇒ voir `JupyterNotebooks/analyse/analyse_journeaux.ipynb`
`JupyterNotebooks/analyse/analyse_speech_brut.ipynb`
`JupyterNotebooks/analyse/deputee_speech_analyse.ipynb`

Dans toute stratégie politique, le langage est un puissant (si ce n'est le plus puissant) levier d'action. Choisir ses mots, répéter certains termes, en éviter d'autres, c'est déjà orienter la perception du réel. En politique, parler, c'est souvent agir. Dès lors il est vitale pour un parti politique de diffuser ses éléments de langage, or les médias sont l'un des plus importants vecteurs de diffusion du langage. Il peut donc être intéressant d'étudier la question suivante : les partis politiques adoptent-ils un langage en phase avec celui des médias ? Afin de répondre à cette question, nous allons étudier l'usage qui est fait des mots dans les médias, et le comparer à celui qu'en font les personnalités politiques. À partir d'une centaine de mots-clés identifiés dans les archives de presse, nous avons comparé, sur une période allant de 2002 à 2022, la fréquence et la distribution de ces termes dans les discours parlementaires et les journaux français (Le Monde, Le Figaro, Libération). Tout d'abord nous allons étudier les différences sémantiques entre les journaux et entre les partis politiques, puis nous comparerons les usages des journaux à ceux des partis.

La première étape de notre analyse consiste à caractériser le vocabulaire des trois journaux étudiés. Après avoir standardisé les fréquences d'utilisation par année et par mot, puis nous avons utilisé kmeans afin d'obtenir 5 clusters de mots pour chaque journaux en se basant sur leur fréquence d'utilisation par année. Chaque cluster regroupe des mots ayant évolué de manière similaire dans le temps. Pour visualiser ces dynamiques, une analyse en composantes principales (PCA) a été réalisée. Elle révèle une structuration très nette de l'espace lexical, avec un axe principal (PC1) capturant près de 95% de l'information.



Ces pca à deux composants représentent 99% de l'information. On constate que pour liberation les mots sont beaucoup moins dispersé selon l'axe 2 que pour les autres sources, de plus on voit clairement que la catégorie à laquelle appartiennent les mots est déterminé par l'axe 1, ce qui est logique puisque celui-ci contient près de 95% de l'information. Afin de comparer les clusters par sources, on peut mesurer la distance cosinus entre leurs centroïdes. Cela nous donne les graphes suivants :




FIGURE 8 – cosme distance entre figaro et le monde




FIGURE 9 – cosme distance entre liberation et le figaro




FIGURE 10 – cosme distance entre le monde et liberation

Ces images nous permettent de constater que les classes 1,2,3 ont des usages assez similaires, cependant les classes 0 et 4 semblent avoir des interactions variables selon les sources. Les profondes différences entre les centroïdes des classes 0 et des classes 1, 2, 3 ainsi que le nombre d'éléments beaucoup plus élevé pour 0 suggère que cette classe contient des mots plus génériques, dont les usages sont très rapprochés, tandis que les classes 1, 2 et 3 sont plus spécialisé, cela est renforcé par le fait que la classe 0 contient 50% des mots et la classe 4 20%, il n'y a donc que peu de mots partagés entre les classes 1, 2 et 3, ce qui indique que leur usage diffère grandement des autres, excepté pour libération dont la classe 4 se rapproche d'avantage du comportement des classes 1, 2, 3 habituelles. On peut donc constater une différence entre libération d'un côté et le monde et le figaro de l'autre. De plus, pour une analyse plus précise on peut se pencher sur les distance cosme entre les classes 1, 2, 3 des sources.

Maintenant nous allons pouvoir comparer cela avec les mêmes corpus mais issus des discours de 180 députés au cours des années 2005 à 2022. Tout d'abord il est intéressant d'étudier l'assemblée nationale :




FIGURE 11 – évolution des députés à l'assemblée nationale

Dans les premières années de la période observée, la scène politique française est largement domi-

née par deux partis : le Parti socialiste et les Républicains (anciennement UMP). Le Parti socialiste, maintient environ 200 députés jusqu'en 2012, ce qui correspond à sa période de plus grande influence, notamment sous la présidence de François Hollande. De leur côté, les Républicains, conservent une position très dominante avec plus de 300 députés de 2007 à 2016. Cette configuration témoigne du bipartisme classique qui structurait alors la vie politique française. Toutefois, à partir de 2017, un basculement profond s'opère. Le mouvement présidentiel porté par Emmanuel Macron, représenté ici sous le nom de Renaissance, émerge avec plus de 300 députés dès sa première participation électorale. Ce renversement marque la fin du duopole PS/LR, et inaugure une période de recomposition politique centrée autour de la majorité présidentielle. Le graphique montre que Renaissance reste le groupe le plus important jusqu'en 2022, bien que l'on observe une importante baisse de ses effectifs à cette date. Parallèlement, de nouveaux acteurs prennent une place croissante dans le paysage parlementaire. La France Insoumise, absente du début de la période, apparaît dès 2017 avec une vingtaine de députés, puis voit ses effectifs augmenter fortement en 2022. Le Rassemblement National, quant à lui, franchit un cap historique en 2022, passant de la marginalité à un groupe d'environ 90 députés. Ce phénomène traduit une montée en puissance des forces dites "périphériques", à droite comme à gauche, qui bénéficient d'un contexte politique de plus en plus fragmenté. D'autres formations, comme Europe Écologie Les Verts ou le Parti communiste français, restent marginales en termes d'effectifs. Cette représentation met également en évidence la diversité croissante des composantes parlementaires, avec l'apparition ou la consolidation de formations centristes telles que le MoDem, les Centristes, Horizons ou encore l'Union des Démocrates et Indépendants. Bien que ces groupes ne dépassent généralement pas les 50 députés, leur rôle est crucial dans la formation des majorités. Ce graphique illustre donc clairement la transition d'un système bipartite vers un paysage multipartite, marqué par l'irruption de forces nouvelles, la fragilisation des partis traditionnels, et la montée d'un centre structuré autour de la majorité présidentielle.

Comme dis précédemment, nous allons observer l'usage que font les parties politiques du vocabulaire que nous avons analysé dans les journaux, et étudier les différences de langage qui résident entre les parties elles-mêmes.




FIGURE 12 – cosme similarité entre les discours des différents partis politiques entre 2006 et 2022

Ce graphe nous permet de constater plusieurs points :

1. Les Républicains et le Parti socialiste : un haut degré de similarité.

Avec une similarité de 0.77, ces deux partis historiquement dominants partagent encore un corpus lexical commun. Cela peut s'expliquer par un socle discursif institutionnel et économique partagé, malgré des oppositions idéologiques sur d'autres plans. Ils restent les deux pôles traditionnels autour desquels se structure la parole publique.

2. La convergence des centristes (Les Centristes et UDI)

Les Centristes et l'UDI affichent une similarité remarquable (0.86) qui confirme leur proximité politique et leur alignement thématique. Ce score élevé suggère un style de discours extrêmement homogène, probablement dominé par des références européennes, consensuelles et modérées.

3. Renaissance : un pont lexical entre blocs

Renaissance est relativement proche de plusieurs formations : 0.76 avec le PS, 0.68 avec LR, 0.73 avec le RN. Ce profil en étoile, reflète son positionnement transpartisan, mais peut aussi traduire une certaine ambiguïté thématique ou l'adoption de références communes à gauche et à droite.

4. Le Rassemblement national : discours distinct mais non isolé

Le RN a une similarité de 0.71 avec le PS et 0.64 avec LR, ce qui pourrait paraître contre-intuitif. Ces chiffres ne signifient pas convergence idéologique, mais possiblement l'adoption de vocabulaires liés aux enjeux populaires : sécurité, pouvoir d'achat, souveraineté. Cela témoigne aussi d'une normalisation

lexicale du RN dans le jeu institutionnel.

5. L'isolement discursif des écologistes et du MoDem

Les scores de Europe Écologie Les Verts sont parmi les plus faibles (ex. 0.36 avec UDI, 0.46 avec PS), indiquant un corpus lexical très spécifique, centré sur les enjeux environnementaux. Le Mouvement Démocrate affiche aussi une faible similarité globale, sauf avec avec les centristes (0.55). Leur score identique à celui du RN est dû à la distribution des données disponible. En effet après étude de ce cas il apparaît que dans les données que nous avons recueillies il n'y a aucun discours du RN et du MODEM dans la même année, ce qui dans notre représentation la distance cosinus vaut 0, et donc la similarité est 1. Mais cela n'est pas représentative d'une réelle relation.

Une étude intéressante à faire serait de regarder l'évolution des similarités entre discours au fil des ans, cependant étant donné la distribution temporelle de nos fichiers ces résultats ne seraient probablement pas représentatifs car nous serions confrontés à de nombreuses situations similaires à celle du RN et du MODEM ici.

Nous pouvons maintenant étudier la similarité cosinus entre les partis et les journaux :




FIGURE 13 – cosinus similarité entre les discours politiques et les journaux

La mesure retenue quantifie à quel point les fréquences de mots employés par chaque parti sont proches de celles observées dans chaque média. Les valeurs varient ici entre 0.13 et 0.25, ces scores de similarités restent très inférieurs à ceux observés entre partis politiques, ce qui montre que le registre journalistique diffère du registre politique. Cependant il y a tout de même des points communs plus ou moins marqués selon les partis. Par exemple on observe que le parti socialiste et les républicains ont une rhétorique similaire à celle du milieu journalistique, probablement dû aux nombreuses années lors desquelles ces deux partis consistaient l'essentiel du paysage politique français. On constate aussi l'influence médiatique de partis qui sont d'avantage d'actualité, comme le RN ou LREM (renaissance). Cependant pour d'autres partis avec moins d'influences (MODEM, centristes, UDI, etc...) les scores de similarités sont largement inférieurs. On peut donc en conclure que la proximité lexicale entre les


rédactions médiatique et les partis politique sont liés, cependant cette proximité est-elle une cause ou une conséquence de l'influence politique de cette proximité? Pour répondre à cette question nous aurions besoin d'un dataset de discours plus riche qui permettrait une étude annuelle de ces similarités. De plus, ce dataset étant basé sur les discours des députés, il y a d'avantage de données pour les partis bénéficiant de plus de députés, ce qui peut biaiser les résultats des analyses, voir empêcher la représentation de certains. Par exemples la France Insoumise n'y est pas représentée, car jusqu'à récemment ce parti bénéficiait de peu de députés et ceux-ci avaient rarement l'occasion de s'exprimer.

3.4 données financières

⇒ voir `JupyterNotebooks/analyse/analyse_finance.ipynb`

La [figure 14](#) illustre l'évolution des flux financiers des partis politiques français, année par année, de 2008 à 2022. Il se compose de plusieurs sous-graphes, chacun représentant les cinq partis ayant enregistré les montants financiers les plus élevés pour une année donnée. Chaque sous-graphe présente, pour chacun de ces partis, les pertes (en rouge) et les gains (en bleu), ce qui permet de comparer leur niveau de dépenses et de recettes au fil du temps. À la lecture de l'ensemble, plusieurs dynamiques apparaissent clairement. Jusqu'en 2012, le Parti socialiste et l'Union pour un Mouvement Populaire (UMP), ancêtre des Républicains, dominent les flux financiers. Ces deux formations apparaissent systématiquement en tête des montants échangés, avec une nette montée en puissance en 2012, année électorale majeure. En effet, cette année-là, les flux financiers atteignent un pic remarquable : l'UMP dépasse les 100 millions d'euros, tandis que le Parti socialiste dépasse les 80 millions. Après 2012, on observe une baisse généralisée des montants échangés, reflet du durcissement des règles de financement, mais aussi de la fin de l'ère du bipartisme. Le Parti socialiste reste dominant jusqu'en 2016, mais avec des montants en nette décroissance. Dès 2015, Les Républicains (anciennement UMP) avec des flux importants mais relativement stables d'une année sur l'autre. Un tournant s'opère à partir de 2017, où apparaît pour la première fois La République en marche (devenue Renaissance), qui s'impose progressivement dans le classement. À partir de cette date, on assiste à une recomposition du paysage financier. La République en marche apparaît régulièrement parmi les partis aux flux les plus élevés, atteignant son apogée en 2020, où elle devance tous les autres partis. Ce phénomène accompagne la conquête et le maintien du pouvoir par Emmanuel Macron et ses soutiens, qui mobilisent d'importants moyens financiers pour structurer leur mouvement et financer leur action électorale. Parallèlement, des partis comme le Parti communiste français ou le Front/Rassemblement national occupent une place modeste mais persistante dans les flux financiers. Le Parti communiste reste présent chaque année, traduisant un grand engagement de sa base électorale, bien que nettement inférieure à celle des grandes formations. Le Rassemblement national, quant à lui, reste en retrait jusqu'à 2018, puis progresse sensiblement à partir de 2019, avec un pic en 2022. Enfin, les flux financiers des partis suivent des cycles assez logiques : ils augmentent sensiblement les années électorales (2012, 2017, 2022), puis retombent à un niveau plus modeste les années suivantes. Cela reflète la réalité structurelle du financement politique, largement rythmé par les échéances électorales qui mobilisent l'essentiel des dépenses et des recettes (subventions publiques, dons, remboursements de campagne...). En somme, ce graphique témoigne non seulement des moyens mobilisés par les différentes formations politiques, mais aussi des transformations du paysage partisan français. Il met en évidence la centralité des grandes échéances électorales, la chute progressive des anciens partis dominants, l'émergence d'un nouveau centre politique autour de La République en marche, et la montée en puissance progressive de formations auparavant marginales comme le Rassemblement national.

Nous avons ensuite appliqué une pca sur notre dataset standardisé, chaque point représente donc un parti politique pour une année. Ensuite nous associons une catégorie à chacun de ces points selon le nombre de député dont bénéficie ce parti. Nous affichons aussi les principales features déterminant l'importance d'un composant.



Ici les features les plus déterminantes sont :

- emprunts et dettes auprès d'établissement de crédit, 0.123, 0.30
- achats de marchandises et variation de stocks, 0.132, -0.275
- cotisations des élus, 0.158, -0.244

Dans ce graphe on constate qu'on peut effectuer une séparation très nette entre les partis qui ont entre 0 et 50 élus et les autres. En effet, aucun partis comportant plus de 50 élus n'a une valeur positive pour les deux composantes, alors que la majorité des partis avec entre 100 et 200 élus, ou plus de 300 se trouvent dans ce cas de figure. Seules exception, les parties avec entre 200 et 300 élus ont tous une composante 2 négative et une composante 1 très forte. On voit également que les variables les plus fortement corrélés à cette distribution sont le taux d'emprunts à des établissements de crédit, donc l'endettement auprès des banques, les achats de biens et les donations des élus du partis. Il y a donc une forte corrélation entre la capacité d'un parti politique à faire élire des députés et à se financer sur les marchés privés.

4 Conclusion

À travers cette étude, nous avons cherché à comprendre ce qui structure, influence et oriente les comportements électoraux contemporains. Plutôt que de réduire cette dynamique complexe à un facteur unique, nous avons fait le pari d'une approche multidimensionnelle, croisant des données issues de multiples sources et reflétant divers facteurs d'influence : opinion, média, discours ou argent.

Notre premier axe d'analyse a porté sur la relation entre les préoccupations de l'opinion publique et les thématiques traitées par les médias. En comparant les réponses au sondage Politbarometer et la couverture de journaux allemands, nous avons mis en évidence une convergence notable sur certaines grandes crises (pandémie, crise économique), mais également des décalages structurels sur des enjeux plus diffus (retraites, environnement). Ce constat questionne le rôle des médias dans la construction de l'agenda politique : s'ils reflètent parfois l'opinion générale, ils peuvent également en dévier et ainsi participer à une forme de cadrage, volontairement ou non.

Nous avons ensuite exploré la possibilité de modéliser le vote individuel à partir de données de sondage, en réduisant la diversité partisane à un clivage gauche/droite. Les résultats de nos modèles de classification (Random Forest, Gradient Boosting) suggèrent que certaines dimensions, notamment économiques, sont prédictives du positionnement politique déclaré. Avec des performances proches de

70% de précision.

Le troisième pilier de notre étude s'est attaché à comparer les vocabulaires utilisés dans la presse et par les partis politiques. À travers une série d'analyses en composantes principales et de mesures de similarité cosinus, nous avons dégagé une géographie sémantique du discours public. Les partis les plus institutionnalisés, comme le PS ou LR, apparaissent plus proches du lexique médiatique dominant, tandis que d'autres, comme EELV ou le RN, développent des langages distincts. Cette hétérogénéité lexicale reflète des choix stratégiques, des positionnements idéologiques, mais aussi des inégalités d'accès à l'espace médiatique.

Enfin, nous avons étudié la structure financière des partis politiques français sur plus d'une décennie. Nos analyses ont montré une forte corrélation entre les ressources disponibles, la capacité à mobiliser des fonds privés, et le poids parlementaire des partis. Les formations dominantes affichent un profil budgétaire bien distinct, davantage d'endettement, plus de dépenses en communication, plus de dons d'élus, que les partis périphériques. Ces observations confirment l'intuition selon laquelle l'argent ne fait pas gagner une élection à lui seul, mais qu'il conditionne fortement la capacité à la disputer. De plus, étant donné le fonctionnement de nos institutions les parties qui ressortent gagnant d'une élection ont accès à davantage de fond public, leur permettant de mieux se positionner lors de la prochaine. Cela a tendance à encrenner encore plus sur leur positions les partis déjà puissants.

Cette étude ouvre plusieurs perspectives. D'abord, une analyse longitudinale plus fine, année par année, des similitudes lexicales entre médias et partis permettrait de mieux comprendre les effets d'apprentissage, d'adaptation ou de rupture dans les discours politiques. De plus, l'intégration des réseaux sociaux, devenus des arènes centrales du débat public, offrirait une vision plus complète de la circulation des idées et de la formation des perceptions.

Car si le vote est un acte individuel, il s'ancre dans un écosystème informationnel et symbolique. C'est ce réseau d'interactions, entre citoyens, médias, partis et institutions, que les outils de la data science permettent aujourd'hui de rendre visible.




FIGURE 14 – Total des flux financiers des partis politiques français

Références

- [1] Alexander ARGANDOÑA-MAMANI et al. « Predicting Election Results with Machine Learning—A Review ». In : *Proceedings of Eighth International Congress on Information and Communication Technology*. Sous la dir. de Xin-She YANG et al. Singapore : Springer Nature Singapore, 2024, p. 989-1001. ISBN : 978-981-99-3043-2.
- [2] Mannheim FORSCHUNGSGRUPPE WAHLEN. *Politbarometer 1977-2023 (Partial Cumulation)*. GESIS, Cologne. ZA2391 Data file Version 16.0.0, [https ://doi.org/10.4232/1.14494](https://doi.org/10.4232/1.14494). 2025. DOI : [10.4232/1.14494](https://doi.org/10.4232/1.14494).